

Proyecto Final

Visión por Computadora

1. Descripción del problema

El presente proyecto aborda el problema de la detección automática de eventos relevantes en partidos de fútbol a partir de secuencias de video. En particular, se busca identificar y clasificar acciones específicas como pases (plays), saques de banda (throw-ins) y disputas del balón (challenges). Dentro de la categoría de disputas del balón, también se puede diferenciar entre las siguientes jugadas: oponente desbordado (opponent rounded), acción con balón ejecutada (ball action carried out), recibir falta (fouled), robo de balón (opponent dispossessed), disputa durante el desprendimiento del balón (challenge during release of the ball) y posesión mantenida tras la disputa (possession retained during challenge). El objetivo es utilizar técnicas de visión por computadora e inteligencia artificial para identificar estas jugadas.

El problema surge debido a que, en la actualidad, la anotación de eventos deportivos se realiza principalmente de forma manual, lo cual implica un alto consumo de tiempo, recursos humanos y costos operativos, además de limitar la disponibilidad de este tipo de datos a ligas profesionales con mayor infraestructura. La detección automática de eventos en video deportivo representa un desafío significativo desde el punto de vista técnico, ya que implica analizar información visual compleja en entornos dinámicos. Factores como el movimiento continuo de los jugadores, variaciones en la iluminación, oclusiones entre objetos, cambios de cámara y la velocidad del juego dificultan la identificación precisa de los eventos. Adicionalmente, la naturaleza temporal del problema exige no solo reconocer patrones espaciales en imágenes individuales, sino también comprender la evolución de las acciones a lo largo del tiempo para determinar el momento exacto en que ocurre un evento.

La resolución de este problema podría tener un impacto directo en la industria deportiva, ya que permitiría automatizar la generación de datos de eventos en partidos de fútbol, facilitando el análisis de rendimiento de jugadores y equipos. Asimismo, abriría la posibilidad de extender estos análisis a ligas más pequeñas o entrenamientos, donde actualmente no se cuenta con los recursos necesarios para realizar anotaciones manuales. En consecuencia, el desarrollo de un sistema de detección de eventos no solo representa un reto técnico relevante, sino también una solución con aplicación práctica y valor en contextos reales.

2. Análisis

El proyecto se enfocó en detectar eventos importantes dentro de partidos de fútbol usando visión por computadora y modelos de deep learning. Para esto se trabajó con clips de video etiquetados provenientes del dataset Bundesliga Data Shootout, donde las jugadas principales eran play, challenge y throwin. También se analizó una segunda clasificación enfocada únicamente en subtipos de challenge, como ball_action_forced, fouled y opponent_dispossessed.

Eventos válidos	4382
Play	3586
Challenge	624
Throwin	172

Durante la exploración inicial de los datos se encontró un problema importante de desbalance entre clases. La mayoría de ejemplos pertenecían a la categoría play, mientras que throwin tenía muchos menos datos disponibles. Esto afectó directamente el entrenamiento de los modelos, ya que las clases con menos ejemplos eran más difíciles de aprender y terminaban teniendo menor precisión en las predicciones.

Otra dificultad importante fue el tamaño reducido del dataset que realmente pudo utilizarse. Aunque el dataset original tenía miles de eventos, únicamente una parte logró mapearse correctamente con los videos .mp4 disponibles. En el notebook se observa que hubo 2087 coincidencias válidas entre eventos y videos, lo cual limitó la cantidad de clips utilizables para entrenamiento.



El problema también tiene una naturaleza temporal compleja porque no basta con analizar una sola imagen. Las jugadas dependen del movimiento de los jugadores y de la evolución de la acción a lo largo de varios frames. Por esta razón, el proyecto utilizó secuencias de

frames consecutivos en lugar de imágenes individuales, permitiendo que el modelo entendiera cambios temporales dentro de la jugada.

Además, las condiciones visuales de los partidos introducen ruido en el proceso de aprendizaje. Existen cambios de cámara, variaciones de iluminación, movimiento rápido y oclusiones entre jugadores que dificultan la extracción de patrones consistentes. Esto explica por qué algunos modelos tuvieron dificultades para generalizar correctamente incluso después de varias épocas de entrenamiento.

3. Propuesta de solución

La solución propuesta para este proyecto consiste en desarrollar un sistema automático de detección de eventos deportivos utilizando técnicas de visión por computadora y deep learning. La idea principal es que el modelo pueda analizar clips de video de partidos de fútbol y reconocer jugadas específicas sin necesidad de intervención manual. Esto permitiría reducir tiempo de anotación, costos operativos y facilitar el acceso a análisis deportivos en contextos donde actualmente no existen suficientes recursos.

Para resolver el problema se planteó el uso de modelos convolucionales capaces de extraer características visuales desde secuencias de frames. Debido a que las jugadas deportivas dependen tanto de información espacial como temporal, la propuesta incluyó arquitecturas capaces de analizar movimiento y evolución de acciones a lo largo del tiempo. Por esta razón se consideró trabajar con secuencias de frames en lugar de imágenes individuales.

La propuesta también contempló el uso de transfer learning mediante modelos preentrenados como EfficientNetB0. Esto permitiría aprovechar características visuales ya aprendidas en datasets grandes y reducir la necesidad de entrenar una red completamente desde cero. Además, esta estrategia ayuda a mejorar estabilidad y disminuir el riesgo de overfitting cuando el dataset disponible es limitado.

Otra parte importante de la propuesta fue evaluar diferentes arquitecturas temporales para determinar cuál se adaptaba mejor al problema. Se consideraron enfoques simples basados únicamente en capas densas y también arquitecturas capaces de procesar secuencias usando Conv1D temporal. La comparación entre arquitecturas permitiría analizar cuál modelo logra capturar mejor el comportamiento dinámico de las jugadas.

Adicionalmente, se propuso trabajar con dos niveles de clasificación. El primero enfocado en eventos generales como play, challenge y throwin, y un segundo nivel especializado en

subtipos de challenge. Esto permitiría analizar si el sistema era capaz de distinguir acciones más específicas y complejas dentro del juego.

Finalmente, la propuesta incluyó técnicas para reducir problemas de desbalance entre clases, ya que algunas jugadas tenían mucha menor cantidad de ejemplos disponibles. Entre las estrategias consideradas estaban el uso de class weights, selección balanceada de muestras y separación estratificada de datos. Estas técnicas buscaban mejorar la capacidad de generalización del modelo y evitar sesgos hacia las clases dominantes.

4. Descripción de la solución

La solución implementada inicia con la carga y limpieza de las etiquetas provenientes del dataset de Hugging Face. Se eliminaron eventos inválidos y se limpiaron los atributos de las jugadas para mantener únicamente información relevante. Después de esto, los eventos se asociaron con los videos .mp4 disponibles para poder extraer clips específicos alrededor de cada acción.

Luego, cada video fue dividido en secuencias de frames usando OpenCV. En la arquitectura principal se utilizaron clips de 8 a 16 frames redimensionados a resoluciones manejables para reducir el costo computacional. Este preprocesamiento permitió alimentar las secuencias directamente al modelo de deep learning.

La arquitectura principal utilizó EfficientNetB0 preentrenada en ImageNet como extractor de características visuales. Las capas convolucionales se mantuvieron congeladas durante gran parte del entrenamiento para aprovechar las características ya aprendidas y reducir overfitting. Después de la extracción visual, las características de cada frame fueron procesadas temporalmente usando Conv1D.

Las capas Conv1D permitieron detectar patrones de movimiento entre frames consecutivos. Finalmente, se agregaron capas densas con activación Softmax para generar la clasificación final de la jugada. Este enfoque resultó más ligero y rápido de entrenar que alternativas recurrentes como LSTM.

Los experimentos mostraron que el Modelo 1 logró resultados limitados pero relativamente estables para clasificación general de eventos. En cambio, el Modelo 2 presentó más dificultad debido a la poca cantidad de ejemplos disponibles para algunos subtipos de challenge. Clases como opponent_rounded y possession_retained tenían muy pocos datos, lo cual redujo significativamente la capacidad de generalización.

La arquitectura temporal con Conv1D funcionó mejor que enfoques más simples porque pudo capturar relaciones entre frames consecutivos. Aun así, los resultados muestran que el problema sigue siendo complejo y probablemente requeriría más datos, mayor balance entre clases y modelos temporales más avanzados para alcanzar mejores métricas.

5. Herramientas aplicadas

Para el desarrollo del proyecto se utilizaron diferentes librerías de Python enfocadas en visión por computadora, procesamiento de datos y deep learning. La mayor parte del entrenamiento se realizó en Google Colab debido a la necesidad de utilizar GPU para procesar secuencias de video y entrenar redes neuronales convolucionales. Esto permitió reducir considerablemente los tiempos de entrenamiento.

OpenCV fue utilizado para cargar videos, extraer frames y realizar el preprocesamiento visual de los clips. Esta librería permitió manipular videos fácilmente y generar secuencias temporales que luego fueron utilizadas por los modelos. También se utilizó para realizar pruebas visuales y verificar que los clips estuvieran correctamente alineados con los eventos.

TensorFlow y Keras fueron las herramientas principales para la construcción y entrenamiento de las redes neuronales. EfficientNetB0 se utilizó mediante transfer learning para extraer características visuales avanzadas desde cada frame. Además, se utilizaron callbacks como EarlyStopping y ReduceLROnPlateau para mejorar la estabilidad del entrenamiento.

Pandas y NumPy se utilizaron para manipular etiquetas, organizar datasets y procesar arreglos multidimensionales de frames. Matplotlib permitió generar gráficas de entrenamiento, matrices de confusión y visualizaciones de resultados. Finalmente, Scikit-learn se utilizó para métricas como accuracy, precision, recall, F1-score y train-test split estratificado.


6. Resultados (métricas)

El presente proyecto evaluó distintas arquitecturas de visión por computadora orientadas a la detección automática de eventos en partidos de fútbol. Los experimentos realizados incluyeron la clasificación de eventos principales del juego (play, challenge y throwin) y posteriormente la clasificación detallada de subtipos de disputas del balón (challenge

subtypes). Para ello, se desarrollaron múltiples modelos utilizando técnicas de transfer learning, procesamiento temporal mediante redes recurrentes y convoluciones temporales.

Los resultados obtenidos evidencian la complejidad del problema, especialmente debido a factores como el movimiento rápido de los jugadores, la similitud visual entre eventos, la variabilidad espacial de las cámaras y la limitada cantidad de datos disponibles. A pesar de estas limitaciones, los modelos implementados permitieron validar la viabilidad técnica del análisis automático de eventos deportivos.

El primer modelo implementado consistió en una arquitectura basada en extracción espacial mediante CNN y modelado temporal utilizando capas LSTM. El objetivo principal fue clasificar tres eventos generales del partido: play, challenge y throwin. Durante el entrenamiento se aplicaron técnicas de transfer learning y data augmentation para mejorar la capacidad de generalización del modelo.



Las curvas de entrenamiento muestran que el modelo presentó dificultades para estabilizar el aprendizaje durante las épocas de entrenamiento. Aunque se observaron ligeras mejoras en la precisión del conjunto de entrenamiento, el desempeño sobre validación permaneció limitado y con fluctuaciones importantes. Este comportamiento sugiere problemas de generalización y evidencia que el modelo tuvo dificultades para aprender representaciones robustas de las distintas jugadas.

De la misma forma, la diferencia entre las curvas de entrenamiento y validación indica la presencia de sobreajuste parcial. Esto puede explicarse principalmente por el tamaño reducido del dataset y por la complejidad temporal de las acciones deportivas. La naturaleza dinámica del fútbol hace que múltiples eventos compartan características visuales similares, dificultando la discriminación entre clases.



Clase	Precision	Recall	F1-Score	Support
0	0.25	0.13	0.17	23
1	0.00	0.00	0.00	23
2	0.14	0.60	0.22	10

Los resultados obtenidos muestran un desempeño limitado en la clasificación de eventos principales del partido. El modelo alcanzó una precisión general cercana al 16%, evidenciando dificultades importantes para distinguir correctamente entre las clases play, challenge y throwin. En particular, la clase 1 no logró ser identificada correctamente, obteniendo valores nulos de precisión y recall.

Por otro lado, la clase 2 obtuvo un recall relativamente alto de 0.60, indicando que el modelo logró detectar varias instancias pertenecientes a esta categoría, aunque con baja precisión. Esto refleja que el modelo tendió a concentrar muchas de sus predicciones en una misma clase, generando una alta cantidad de falsos positivos. La limitada resolución de entrada y la poca cantidad de frames por clip probablemente afectaron la capacidad del modelo para capturar patrones temporales complejos.

El Modelo 1 presentó un desempeño limitado en la clasificación de eventos principales del partido, alcanzando una precisión cercana al 34%. Los resultados obtenidos muestran que el modelo tendió a concentrar la mayoría de sus predicciones en una sola clase, específicamente challenge, evidenciando dificultades para diferenciar correctamente entre play, challenge y throwin. Este comportamiento puede atribuirse principalmente al tamaño reducido del dataset utilizado, la limitada cantidad de frames por clip y la reducción de resolución implementada para ajustarse a las restricciones computacionales del entorno de entrenamiento.

Luego, se implementó una nueva arquitectura basada en una CNN congelada para extracción espacial y capas Conv1D para modelado temporal.



Las curvas de entrenamiento muestran un comportamiento más estable respecto al Modelo 1. La precisión alcanzó valores superiores durante las épocas de entrenamiento y la pérdida disminuyó de manera más consistente. Esto sugiere que la nueva arquitectura logró extraer características espaciales más robustas y representar mejor la dinámica temporal de las jugadas.


A diferencia del modelo anterior, la convergencia fue más estable y presentó menor variabilidad entre entrenamiento y validación. Esto indica una mejora en la capacidad de generalización y evidencia que el uso de convoluciones temporales puede ser más efectivo para este tipo de tareas deportivas.

Clase	Precision	Recall	F1-Score	Support
Play	0.44	0.33	0.38	12
Challenge	0.28	0.42	0.33	12
Throwin	0.12	0.09	0.11	11

La nueva arquitectura logró mejorar significativamente el desempeño general del sistema, alcanzando un accuracy cercano al 29%, superando considerablemente los resultados obtenidos por el Modelo 1. La clase play obtuvo el mejor desempeño general, alcanzando un F1-score de 0.38 y una precisión de 0.44. Esto indica que el modelo fue capaz de identificar de manera más consistente este tipo de evento.

La clase challenge también presentó mejoras importantes respecto al modelo anterior, especialmente en recall, alcanzando un valor de 0.42. Sin embargo, la clase throwin continuó siendo la más difícil de clasificar, posiblemente debido a la baja cantidad de muestras y a la similitud visual con otras acciones del juego. En términos generales, los resultados demuestran que la nueva arquitectura basada en Conv1D temporal permitió capturar mejor las relaciones temporales entre frames consecutivos. Esto evidencia que la selección de arquitectura tiene un impacto directo sobre el desempeño del sistema de detección automática de eventos deportivos.

Posteriormente, se desarrolló un modelo especializado para la clasificación de subtipos de disputas del balón (challenge subtypes). Este experimento buscó diferenciar acciones más específicas dentro de las jugadas de contacto entre jugadores.



Las curvas de entrenamiento muestran un comportamiento considerablemente más inestable que en los modelos anteriores. La precisión permaneció baja durante gran parte del entrenamiento y la pérdida presentó fluctuaciones importantes. Esto evidencia la dificultad de clasificar eventos altamente específicos y visualmente similares. La clasificación de subtipos de challenge representa un problema mucho más complejo debido a que las diferencias entre clases son mínimas y dependen fuertemente del contexto temporal de la jugada. Además, el reducido número de muestras por categoría afectó significativamente la capacidad de aprendizaje del modelo.

Clase	Precision	Recall	F1-Score	Support
Ball_action_forced	0.00	0.00	0.00	3
Fouled	0.00	0.00	0.00	3
Opponent_dispossessed	0.20	0.67	0.31	3
Opponent_rounded	0.00	0.00	0.00	3
Possession_retained	0.00	0.00	0.00	3

El modelo alcanzó una precisión general cercana al 13%, evidenciando la alta complejidad de la clasificación fina de eventos deportivos. Únicamente la clase `opponent_dispossessed` logró ser detectada parcialmente, obteniendo un recall de 0.67. Sin embargo, las demás categorías no lograron ser clasificadas correctamente. Estos resultados muestran que la clasificación detallada de eventos requiere una cantidad considerablemente mayor de datos y arquitecturas más especializadas para modelar información temporal compleja. La similitud visual entre eventos y la corta duración de las acciones dificultan significativamente la extracción de patrones discriminativos.

Predicciones de modelo

Los ejemplos visuales de predicción permiten observar el comportamiento del modelo sobre frames individuales extraídos de los videos. En varios casos, el sistema logró identificar correctamente eventos principales como play, mostrando niveles de confianza relativamente altos. Por ejemplo, una de las predicciones obtenidas fue:

play | conf: 0.68



Probabilidades:

play: 0.683

challenge: 0.285

throwin: 0.032

Estos resultados muestran que el modelo logró aprender ciertas características discriminativas asociadas a eventos específicos. Sin embargo, también puede observarse incertidumbre entre categorías visualmente similares, especialmente entre play y challenge. Esto confirma nuevamente la dificultad del problema y la necesidad de incorporar arquitecturas temporales más robustas.

Asimismo, para el modelo de subtipos de challenge, se obtuvo la siguiente predicción:

Prediccion: ball_action_forced

- confianza: 0.760

Probabilidades:

- ball_action_forced: 0.760
- fouled: 0.162
- opponent_dispossessed: 0.055
- opponent_rounded: 0.008
- possession_retained: 0.015

La distribución de probabilidades evidencia que el modelo fue capaz de asignar mayor confianza a ciertas clases específicas. Aunque el desempeño global todavía es limitado, estos ejemplos muestran que el sistema logró capturar parcialmente información espacial y temporal relevante para la clasificación automática de eventos deportivos.

7. Conclusión

El proyecto permitió comprobar que sí es posible aplicar técnicas de visión por computadora e inteligencia artificial para detectar automáticamente eventos en partidos de fútbol. A lo largo de los experimentos se implementaron distintas arquitecturas capaces de clasificar jugadas como play, challenge y throwin, además de subtipos específicos de disputas del balón. Aunque las métricas obtenidas todavía son limitadas, los resultados demostraron que el sistema logró aprender ciertos patrones espaciales y temporales presentes en las jugadas.

También se observó que la clasificación de eventos deportivos es un problema bastante complejo debido al movimiento constante de los jugadores, la similitud visual entre acciones y la poca cantidad de datos disponibles. El primer modelo basado en CNN + LSTM presentó dificultades importantes para diferenciar correctamente las clases, mientras que la segunda arquitectura utilizando CNN congelada y Conv1D temporal logró mejorar el desempeño general y obtener resultados más estables. Por otro lado, la clasificación de subtipos de challenge resultó ser la tarea más difícil, ya que las diferencias entre categorías son muy pequeñas y dependen mucho del contexto temporal de la jugada.

En general, el proyecto permitió desarrollar un pipeline completo de análisis de video deportivo utilizando deep learning, validando la viabilidad técnica de este tipo de soluciones para automatizar el análisis de partidos. Además, los resultados dejan claro que futuras mejoras podrían lograrse utilizando datasets más grandes, modelos temporales más

avanzados y técnicas especializadas para captura de movimiento. A pesar de las limitaciones actuales, el trabajo realizado constituye una base sólida para continuar desarrollando sistemas automáticos de análisis deportivo con aplicaciones reales dentro de la industria del fútbol.

8. Bibliografía

Kaggle (2024). *DFL Bundesliga 460 MP4 videos in 30 sec + CSV* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/saberghaderi/-dfl-bundesliga-460-mp4-videos-in-30sec-csv>