

Segmentación de imágenes mediante Matriz de Afinidad y Laplaciano Normalizado

Ariela R. Mishaan (22052), Alina T. Carías (22539), Ingeniería en Ciencia de los Datos, UVG

Abstract—An image segmentation approach is presented based on the construction of an affinity graph between pixels and the application of the normalized Laplacian to extract the Fiedler vector. The method was tested on different images, carrying the parameter alpha, beta, and sigma, which regulate color similarity, relative position, and the smoothness of the Gaussian function. Binary segmentations with significant differences between configurations were obtained, highlighting the sensitivity of the method. In addition, the effects of image reduction, the direction of segmentation cuts, and the possibility of using grayscale images are discussed.

Resumen—Se presenta un enfoque de segmentación de imágenes basado en la construcción de un grado de afinidad entre píxeles y la aplicación del laplaciano normalizado para extraer el vector de Fiedler. El método se probó sobre distintas imágenes, variando los parámetros alfa, beta y sigma que regulan la similitud de color, la posición relativa y la suavidad de la función gaussiana. Se obtuvieron segmentaciones binarias con diferencias significativas entre configuraciones, evidenciando la sensibilidad del método. Además, se discuten los efectos de la reducción de imágenes, la dirección de los cortes de segmentación y la posibilidad de utilizar imágenes en escala de grises.

Palabras clave—Segmentación de imágenes, vector de Fiedler, laplaciano normalizado, matriz de afinidad, alfa, beta, sigma.

I. INTRODUCCIÓN

La segmentación de imágenes es un paso fundamental en el procesamiento digital de imágenes, con aplicaciones en visión por computadora, análisis biomédico y reconocimiento de patrones. Una técnica ampliamente utilizada se basa en la representación de la imagen como un grafo de píxeles, donde la similitud entre nodos se mide mediante características como color y posición. A partir de esta representación, se construye la matriz de afinidad y se obtiene el laplaciano normalizado, lo cual permite separar regiones de interés.

En este proyecto se aplicó dicho método sobre diferentes imágenes, variando parámetros clave (alfa, beta, sigma) para analizar su efecto en los resultados obtenidos. El objetivo es determinar configuraciones que generen segmentaciones más precisas y robustas.

II. DISEÑO EXPERIMENTAL

Para ver el proceso completo, ver Anexo 2 (archivo .ipynb).

A. Lectura y reducción de imágenes

Como primer paso se escogieron imágenes con fondos sólidos y figuras centrales bastante distintivas, con el objetivo de ver el funcionamiento del algoritmo en un escenario óptimo (ver las imágenes escogidas en el Anexo 1). Se empleó una reducción inicial para cada imagen (ej. 60x40 píxeles) para disminuir el número de nodos y facilitar el cómputo.

B. Cálculo de afinidad entre píxeles

Para “conectar” a cada pixel con sus vecinos inmediatos (arriba, abajo, izquierda, derecha), se utilizó la métrica de afinidad del kernel gaussiano, que tiene la siguiente fórmula:

$$s = \exp\left(-\frac{\alpha \|c_i - c_j\|^2 + \beta \|p_i - p_j\|^2}{2\sigma^2}\right)$$

Donde c representa color y p posición. Con estos valores se construyó la matriz de afinidad “ W ”, una matriz rala por la falta de conexiones entre píxeles no conectados directamente.

C. Obtención del Laplaciano normalizado

Después de obtener la matriz de afinidad “ W ”, se obtuvo la matriz Laplaciana normalizada de W con la siguiente fórmula:

$$L_{norm} = I - D^{-\frac{1}{2}} W D^{-\frac{1}{2}}$$

Donde “ D ” es la matriz diagonal

$$D = \text{diag}(d_1, d_2, \dots, d_{hw})$$

(hw es el alto x ancho de la matriz).

D. Vector de Fiedler:

Utilizando métodos “sparse” de python, se calcularon los autovalores y autovectores del laplaciano normalizado. Se extrae el autovector asociado al segundo menor autovalor de esta matriz, llamado el vector de Fiedler.

E. Segmentación binaria

El vector de Fiedler se normaliza y se generan máscaras binarias a partir del mismo. Se asigna un color distinto a los valores negativos de este vector y a los valores positivos.

F. Comparación experimental

Después de realizar las funciones necesarias en python, se cargan varias imágenes y se compara su rendimiento, variando los parámetros alfa, beta y sigma.

III. RESULTADOS

Para ver resultados gráficos completos, dirigirse al Anexo 1.

Al aplicar el método de observaron patrones claros:

- En imágenes simples y con contraste fuerte, las segmentaciones fueron exitosas, especialmente con valores equilibrados de $\alpha = 1, \beta = 1, \sigma = 0.1$
- Al anular el parámetro del color ($\alpha = 0$), la segmentación no funcionó, generando imágenes muchas veces segmentadas en mitades arbitrarias.
- La anulación de la posición ($\beta = 0$) resultó en segmentaciones tan exitosas como para la combinación $\alpha = 1, \beta = 1, \sigma = 0.1$.
- El aumento de σ suavizó excesivamente las diferencias y redujo la capacidad del método de detectar bordes finos.

En las figuras del anexo 1 se muestran cómo, dependiendo de los parámetros, una misma imagen podía dividirse en regiones coherentes o, en casos extremos, quedar con cortes diagonales o verticales poco naturales. En particular, se observaron segmentaciones que dividían imágenes a la mitad, lo que indica que la estructura global de la afinidad puede dominar sobre detalles locales.

En general, la reducción de imágenes a resoluciones pequeñas permitió obtener resultados rápidos y razonables, aunque con pérdida de detalle en los bordes más finos.

IV. DISCUSIÓN DE RESULTADOS

Los experimentos realizados muestran con claridad que los parámetros alfa, beta y sigma tienen un efecto determinante en la calidad de segmentación. En primer lugar, el parámetro alfa, que controla el peso del color en la similitud entre píxeles, resultó fundamental para preservar la coherencia visual de las regiones. Cuando alfa se mantuvo alto, las segmentaciones lograron diferenciar áreas basadas en diferencias de color, lo cual fue especialmente útil en imágenes con contrastes marcados. En cambio, al reducirlo o incluso fijarlo en cero, el algoritmo dejó de considerar la información de color, lo que

condujo a cortes arbitrarios y segmentaciones menos precisas. Esto evidencia que, en la mayoría de casos, el color es una característica indispensable para definir bordes naturales en las imágenes.

En cuanto al parámetro beta, se observó que su presencia puede contribuir en las segmentaciones, pero como se muestra en el anexo 1, no es del todo esencial. La anulación de beta resultó en algunos casos, como en el de las imágenes 5 y 8, mucho más productiva que su uso.

Un aspecto adicional a discutir fue la reducción de las imágenes antes del procesamiento. Aunque permitió mejorar la eficiencia y facilitar las pruebas, también se perdieron detalles en los bordes, lo que afectó la precisión en objetos pequeños o con texturas complejas. También se observó que ciertas configuraciones generaban cortes a la mitad de la imagen, usualmente siguiendo líneas verticales u horizontales. Esto podría tener que ver con la configuración de la imagen, o de aspectos como el color. Se requiere de una muestra más grande de imágenes específicas para poder determinar cuál es la razón de este fenómeno.

Finalmente, se reflexionó sobre posibles mejoras al método. Una alternativa interesante sería trabajar con imágenes en escala de grises, lo que podría reducir el ruido de colores y simplificar los cálculos. Asimismo, probar segmentaciones multiclase en lugar de binarias permitiría obtener particiones más naturales y útiles en aplicaciones prácticas.

V. CONCLUSIONES

- Se pudo comprobar que la segmentación de imágenes basada en el vector de Fiedler es una técnica sensible a la configuración de los parámetros alfa, beta y sigma, los cuales determinan la calidad y estabilidad de los resultados.
- En general, se observó que la combinación de información de colores y de posición ofrece segmentaciones coherentes. Mientras que ignorar la posición de los píxeles dio resultados positivos, el color es fundamental en la segmentación, ya que su anulación genera resultados incorrectos.
- La reducción de la resolución de las imágenes resultó útil para agilizar el procesamiento, aunque a costa de sacrificar detalles finos en los bordes y texturas.
- Se identificó que en ciertas configuraciones el algoritmo tiende a producir particiones sin sentido a la primera vista.

VI. RECOMENDACIONES

A partir de los resultados obtenidos, se recomienda realizar pruebas adicionales con imágenes de diferentes resoluciones para evaluar de manera más precisa el compromiso entre eficiencia y calidad de segmentación. También sería conveniente explorar la segmentación en escala de grises, lo

cual podría simplificar los cálculos y reducir el ruido cromático en imágenes donde el color no aporta información esencial. Asimismo, se sugiere implementar un ajuste de los parámetros, en especial de sigma, de acuerdo con la varianza de color y estructura de cada imagen, con el fin de mejorar la estabilidad del método.


VII. BIBLIOGRAFÍA

- [1] von Luxburg, U. (2007). *A tutorial on spectral clustering*. Statistics and Computing, 17(4), 395–416. Springer. <https://doi.org/10.1007/s11222-007-9033-z>
- [2] Ding, C. (2004). *A tutorial on spectral clustering* [Part 1: Basic Theory]. Lawrence Berkeley National Laboratory, University of California. Tutorial presentado en ICML 2004.
- [3] Ding, C. (2004). *A tutorial on spectral clustering* [Part 2: Advanced/related topics]. Lawrence Berkeley National Laboratory, University of California. Tutorial presentado en ICML 2004.

VIII. ANEXO 1

Resultado de variación de parámetros en las distintas imágenes

A continuación, se muestran las fotos utilizadas para realizar las pruebas de la segmentación binaria, seguidas por una tabla de comparación, que contrasta los resultados según los valores de los parámetros alfa (color), beta (lugar) y sigma utilizados para calcular la similitud de píxeles (ver procedimiento completo y código en Anexo 2)

α	β	σ	Imagen 1 	Imagen 2 	Imagen 3 	Imagen 4 
1	1	0.1				
1	1	1				
1	1	10				
1	1	100				
0.1	0.1	0.1				
0	1	0.1				

1	0	0.1				
α	β	σ	Imagen 5 	Imagen 6 	Imagen 7 	Imagen 8 
1	1	0.1				
1	0	0.1				