

# Predicción FIFA World Cup 2026 mediante Aprendizaje Estadístico

Ariela R. Mishaan (22052), Alina T. Carías (22539) *Ingeniería en Ciencias de los Datos, UVG*

**Abstract—** This project applies statistical learning techniques to predict outcomes of the FIFA World Cup 2026, which for the first time features 48 national teams. We construct a comprehensive dataset integrating historical match data spanning 1872–2025 (43,364 international matches), FIFA video game player ratings (versions 15–24), Transfermarkt market valuations, and World Bank socioeconomic indicators for each national team. Three complementary modeling tasks are addressed: (1) predicting the furthest round each team will reach (multiclass classification), (2) predicting match winner and scoreline for each fixture (classification and regression), and (3) estimating championship probabilities through a Monte Carlo tournament simulation with 10,000 runs.

**Resumen—** Este proyecto aplica técnicas de aprendizaje estadístico para predecir los resultados del FIFA World Cup 2026, el primer torneo con 48 selecciones nacionales. Se construyó un dataset maestro integrando cinco fuentes de datos: partidos internacionales históricos (1872–2025), ratings de jugadores del videojuego FIFA, valoraciones de mercado de Transfermarkt, indicadores socioeconómicos del Banco Mundial, y el calendario oficial de fixtures del torneo 2026. Se abordaron tres tareas de modelado complementarias: (1) predicción de la ronda máxima que alcanzará cada selección, (2) predicción del resultado y marcador de cada partido, y (3) estimación de probabilidades de campeonato mediante simulación Monte Carlo con 10,000 iteraciones. Los modelos se optimizaron mediante Grid Search con validación cruzada de 5 folds.

**Palabras clave—** aprendizaje estadístico, predicción fútbol, simulación Monte Carlo, gradient boosting, random forest, ELO, FIFA World Cup 2026, clasificación multiclase, simulación de torneo

## I. INTRODUCCIÓN

El fútbol es uno de los fenómenos culturales y económicos más significativos a escala global. La copa del mundo FIFA, el mundial, concentra la atención de miles de millones de personas y genera posibilidades de hacer predicciones, quinielas y análisis estadístico cada vez más elaborado. El torneo de 2026 representa además un reto adicional, ya que por primera vez se enfrentarán 48 selecciones en lugar de 32, expandiendo el campo de participantes y añadiendo complejidad al proceso predictivo.

La predicción de resultados deportivos es un problema clásico del aprendizaje estadístico. Combina fuentes de datos heterogéneas (estadísticas históricas de equipos, calidad individual de los jugadores, contexto socioeconómico y forma reciente) con modelos capaces de capturar relaciones no lineales entre estas variables y los resultados observados. El reto principal radica en que el fútbol posee alta varianza: incluso con grandes diferencias de calidad entre equipos, el

resultado individual de un partido es difícil de predecir con alta certeza.

Este proyecto aborda este reto desde tres ángulos complementarios. Primero, construye un modelo de clasificación multiclase que predice hasta qué ronda llegará cada selección (de fase de grupos hasta campeón), incorporando la restricción de cupos reales del torneo para que las predicciones sean coherentes con la estructura del bracket del mundial. Segundo, entrena modelos de clasificación y regresión para predecir el resultado (victoria local, empate, victoria visitante) y el marcador exacto de cada partido. Tercero, integra estos modelos en una simulación Monte Carlo que simula 10 000 veces el torneo completo, generando probabilidades de campeonato consistentes con los modelos de partido. El sistema también contempla la actualización de predicciones a medida que avanza el torneo real.

## II. DESCRIPCIÓN DE LOS DATOS

Se integraron cinco fuentes de datos de naturaleza y granularidad distintas. La unidad de análisis central es el par selección-torneo para el modelo de ronda, y el partido individual para el modelo de resultado. A continuación se describe cada fuente.

### A. Partidos internacionales históricos

La fuente principal es el dataset *teams\_match\_features*, que cubre 43 364 partidos internacionales desde el 30 de noviembre de 1872 (primer partido oficial de la historia, Escocia vs. Inglaterra) hasta diciembre de 2025. Cada fila representa un partido e incluye ratings ELO<sup>1</sup> de ambos equipos, estadísticas de forma reciente (goles anotados y encajados por partido, win rate en ventana de tiempo), ratings promedio de plantilla, y variables de contexto como si el partido es neutral, si es un mundial o si es una competencia continental.

Las categorías de torneo más representadas son partidos amistosos (15 272), clasificaciones para la copa del mundo (7054), clasificatorias del Campeonato Europeo (2724) y partidos de copa del mundo (928). El 100% de los registros cuenta con valores ELO no nulos.

<sup>1</sup> El Elo rating (o sistema de puntuación Elo) es un método matemático y estadístico diseñado para calcular la habilidad relativa de los jugadores en juegos de confrontación, como el ajedrez. Su objetivo principal es predecir el resultado de una partida y actualizar las puntuaciones de ambos jugadores en consecuencia.

Fuente: Kaggle – International football results dataset / ELO ratings históricos.

### B. Resultados de Copas del Mundo (1930 – 2022)

El archivo *world\_cup\_matches* (852 partidos, tras limpieza) contiene los resultados de todos los partidos de Copa del Mundo entre 1930 y 2014 con anotación de etapa, goles y equipos. Para 2018 se incorporaron los datos del archivo *World Cup 2018 Dataset.csv* y para 2022 el archivo *Fifa\_world\_cup\_matches\_2022.csv* (64 partidos, 88 variables estadísticas detalladas). Con esta información se construyó el target *stage\_reached* para el modelo de ronda, asignando a cada selección mundial la ronda más avanzada que alcanzó.

La distribución del target presenta desbalance natural: 263 equipos en fase de grupos, 80 en octavos, 68 en cuartos, 38 en semis, 21 finalistas y 21 campeones. Para gestionar ese desbalance, los modelos de clasificación usaron *class\_weight = 'balanced'*.

Fuente: Kaggle – FIFA World Cup Dataset / World Cup Matches

### C. Ratings de Jugadores FIFA (EA Sports)

El dataset *player\_aggregates* contiene 1,599 registros de estadísticas agregadas por país y versión del videojuego FIFA (versiones 15 a 24). Cada registro incluye número de jugadores, rating promedio general, máximo overall, y promedios de velocidad, disparo, pase, regate, defensa y físico. Se mapearon las versiones del juego a los mundiales correspondientes (FIFA 18 → WC 2018, FIFA 22 → WC 2022, FIFA 24 → WC 2026), resultando en 488 registros con mundial asignado.

Fuente: Kaggle — FIFA Players Statistics (EA Sports).

### D. Valoraciones de Mercado (Transfermarkt)

El dataset *player\_valuations* contiene 507,815 registros de valoraciones individuales de jugadores entre 2000 y febrero de 2026. Dado que las valoraciones no incluyen directamente la selección nacional del jugador, se agregaron por liga doméstica y año para construir un indicador de riqueza de plantilla a nivel de competición. Este dataset contextualiza el nivel económico de cada liga, proxy de la calidad de los jugadores disponibles para cada selección.

Fuente: Kaggle — Transfermarkt Player Valuations.

### E. Indicadores socioeconómicos (World Bank API)

Se descargaron mediante la API del Banco Mundial cinco indicadores macroeconómicos para todos los países y los años de los mundiales: PIB per cápita (NY.GDP.PCAP.CD), población total (SP.POP.TOTL), porcentaje de población

urbana (SP.URB.TOTL.IN.ZS), penetración de internet (IT.NET.USER.ZS) y desempleo (SL.UEM.TOTL.ZS). Cada indicador proveyó 17,556 observaciones. Se mapearon a los equipos del dataset maestro usando un diccionario de normalización de nombres (por ejemplo, 'England' → 'United Kingdom', 'South Korea' → 'Korea, Rep.').

Fuente: World Bank Open Data API

### F. Fixtures del Mundial 2026

El calendario oficial del torneo (FIFA2026\_schedule\_Fixtures.csv) contiene 104 partidos con información de fecha, número de partido, equipos, grupo y estadio. Los 48 equipos clasificados se distribuyeron en 12 grupos de 4 equipos. Para los partidos de fases eliminatorias el fixture incluye etiquetas genéricas como 'Winner Group A', que se gestionan mediante el simulador.

Fuente: Kaggle – Fixtures FIFA World Cup 2026

## III. EXPLORACIÓN DE DATOS

### A. Dataset Maestro

El dataset maestro final combina las cinco fuentes en 491 registros (uno por selección-mundial), con 27 variables. Cubre 22 mundiales desde 1930 hasta 2022. El número de selecciones por torneo creció de 13 en 1930 hasta 32 a partir de 1998. Los datos de *player\_aggregates* cubren solo 2018, 2022 y 2026; los registros de torneos anteriores dependen exclusivamente de las variables futbolísticas.

### B. Correlación de variables con la ronda alcanzada

Se calculó la correlación de Pearson de todas las variables numéricas con *stage\_encoded* (0=grupos, 5=campeón). Las cinco variables con mayor correlación positiva fueron:

TABLA 1. CORRELACIÓN DE PEARSON CON LA RONDA ALCANZADA (TOP 5)

| Variable                                     | Correlación con Ronda |
|----------------------------------------------|-----------------------|
| <i>pa_avg_overall</i> (rating FIFA promedio) | 0.569                 |
| <i>pa_max_overall</i> (rating FIFA máximo)   | 0.478                 |
| <i>avg_attack</i> (ataque pre-torneo)        | 0.409                 |
| <i>avg_overall</i> (overall pre-torneo)      | 0.405                 |
| <i>avg_defense</i> (defensa pre-torneo)      | 0.383                 |

Los ratings del videojuego FIFA muestran la correlación más fuerte con el desempeño real en el torneo, lo que valida su uso como proxy de calidad de plantilla. Las variables socioeconómicas (PIB per cápita, población) mostraron correlaciones más débiles pero positivas.





Fig. 1: Correlación de variables con la ronda alcanzada

### C. Distribución del target

La variable objetivo `stage_reached` presenta el desbalance esperado en una estructura eliminatoria: el 53.6% de las observaciones corresponden a fase de grupos, el 16.3% a octavos, el 13.8% a cuartos, el 7.7% a semifinales, y el 4.3% respectivamente a finalistas y campeones. Este desbalance es inherente al diseño del torneo y requiere estrategias específicas de manejo en los modelos.


 Fig. 2: distribución del target `stage_reached`.

### D. Distribución de resultados de partidos

En el dataset de 43,364 partidos internacionales, el 56.5% terminó con victoria local, el 23.5% con empate y el 20.1% con victoria visitante. Esta ventaja de localía es consistente con la literatura deportiva y se incorpora como feature (`is_neutral = 1` para partidos neutrales como en la Copa del Mundo).

### E. Análisis de Componentes Principales (PCA)

Se aplicó PCA sobre las 8 variables futbolísticas continuas (ELO, `win_rate`, `goals_scored_pg`, `goals_conceded_pg`, `goal_diff_pg`, `avg_attack`, `avg_defense`, `avg_overall`). El primer componente explicó el 51.1% de la varianza, el segundo el 25.5% y el tercero el 15.7%, alcanzando el 85% de varianza acumulada con tan solo 3 componentes.




Fig. 3: Varianza explicada por componente PCA características de equipos.

Como se puede ver en el gráfico de Loadings, PC1, por ejemplo puede interpretarse como un índice general de calidad futbolística, fuertemente cargado en ELO, `win_rate` y ataque. Para las variables socioeconómicas, los dos primeros componentes explicaron el 65.5% de la varianza.




Fig. 4: Loadings de PCA para las 3 componentes principales

### F. Clustering K-Means

Usando el método del codo se identificaron 4 clusters óptimos sobre el espacio PCA futbolístico: potencias históricas (ELO y `win_rate` altos), selecciones de nivel medio-alto, selecciones competitivas pero irregulares, y selecciones débiles. Los clusters mostraron correlación clara con la ronda alcanzada: el cluster de potencias concentra la mayoría de los campeones y finalistas.




Fig. 5: Perfil de clusters según variables incorporadas

## IV. SELECCIÓN DE VARIABLES

### A. Variables del modelo de partido

Se construyó un conjunto de 19 features para el modelo de resultado de partido, divididas en tres grupos:

- **Diferencias de calidad:** `elo_diff`, `attack_diff`, `defense_diff`, `overall_diff` — diferencia entre el equipo local y el visitante en cada métrica.

- **Forma reciente:** home\_form\_scored, home\_form\_conceded, home\_form\_win\_rate y sus equivalentes para el equipo visitante — estadísticas de los partidos previos en ventana de 2 años.
- **Variables de contexto e interacción:** is\_neutral, is\_world\_cup, is\_continental, elo\_sq (efecto cuadrático del ELO), attack\_vs\_defense (ataque local vs defensa visitante), attack\_vs\_defense\_inv, form\_diff\_scored, form\_diff\_conceded, form\_diff\_win\_rate.

La inclusión de términos cuadráticos (elo\_sq) y de interacción permite al modelo capturar relaciones no lineales: la diferencia de ELO tiene mayor impacto en los extremos que en enfrentamientos equilibrados.

### B. Variables del modelo de ronda

Para el modelo de ronda alcanzada se utilizaron 13 variables del dataset maestro: ELO, win\_rate, goals\_scored\_pg, goals\_conceded\_pg, goal\_diff\_pg, avg\_attack, avg\_defense, avg\_overall (calculadas en los 2 años previos a cada torneo), pa\_avg\_overall, pa\_max\_overall (ratings FIFA), gdp\_per\_capita, population y urban\_population\_pct.

La ventana temporal de 2 años antes del torneo es clave para evitar data leakage: las features de cada mundial se calculan exclusivamente con partidos anteriores a ese torneo, nunca con datos del torneo en cuestión.

### C. Criterio Anti-Leakage

La función get\_team\_features\_before\_wc() recorta los datos con cutoff\_date = 31 de mayo del año del mundial, garantizando que ningún partido del torneo contamina las features. Las variables pa\_avg\_overall corresponden a la versión FIFA lanzada en septiembre del año previo al mundial. Los indicadores del Banco Mundial usan el año exacto del mundial.

## V. METODOLOGÍA

### A. Pipeline General

El pipeline completo tiene seis etapas secuenciales:

- **Carga y limpieza:** normalización de nombres de países, estandarización de etapas de torneo, corrección del flag is\_world\_cup.
- **Construcción del target:** asignación de stage\_reached por selección-mundial con función upgrade\_stage() que solo actualiza si la nueva etapa es superior a la registrada.
- **Feature engineering:** cálculo de métricas futbolísticas en ventana temporal, merge con ratings FIFA, merge con indicadores socioeconómicos.
- **Entrenamiento de modelos supervisados:** modelo de resultado de partido y modelo de ronda alcanzada, ambos con Grid Search y CV de 5 folds.

- **Simulación Monte Carlo:** 10,000 simulaciones del torneo completo usando probabilidades del modelo de partido.
- **Exportación:** generación de CSVs de quiniela y predicciones de ronda para uso externo.

### B. Modelo de Resultado de partido

Se compararon cinco modelos de clasificación (tres clases: local gana = 1, empate = 0, visitante gana = -1): Regresión Logística, Random Forest base, Random Forest optimizado, Gradient Boosting base, Gradient Boosting optimizado, y XGBoost. La evaluación usó división temporal: datos hasta diciembre 2021 para entrenamiento (39,915 partidos) y datos desde 2022 para test (3,449 partidos). Las features se estandarizaron con StandardScaler ajustado solo sobre el conjunto de entrenamiento.

Se realizó Grid Search con 5-fold cross validation. Para Random Forest se exploró n\_estimators ∈ {100, 200, 300}, max\_depth ∈ {None, 5, 10} y min\_samples\_split ∈ {2, 5}. Para Gradient Boosting: n\_estimators ∈ {100, 200}, learning\_rate ∈ {0.05, 0.1}, max\_depth ∈ {3, 5} y subsample ∈ {0.8, 1.0}. Para XGBoost se añadió colsample\_bytree ∈ {0.8, 1.0}.

Para la predicción en partidos neutrales del Mundial (simulación y quiniela), se implementó un promediado simétrico: se genera la predicción con A como 'local' y con B como 'local', y se promedian las probabilidades para eliminar el sesgo de localía.

### C. Modelo de Ronda Alcanzada

La clasificación multiclase de ronda (6 clases ordinales) se entrenó sobre el dataset maestro con división temporal: mundiales hasta 2018 como entrenamiento (31 equipos/mundial efectivos) y 2022 como test (30 equipos). Se usó class\_weight='balanced' para compensar el desbalance de la estructura eliminatória.

Se compararon Regresión Logística, Random Forest y Gradient Boosting con sus versiones base y optimizadas por Grid Search (RF: n\_estimators ∈ {100, 200, 300}; GB: learning\_rate ∈ {0.05, 0.1}, max\_depth ∈ {3, 5}), más XGBoost. Se añadió la restricción de cupos: las probabilidades crudas del modelo se usan para asignar de forma greedy exactamente 1 campeón, 1 runner-up, 2 semifinalistas adicionales, 4 cuartos adicionales y 8 equipos en octavos, reflejando la estructura real del torneo.

### D. Predicción de Goles

Se entrenaron modelos de regresión (Random Forest y Gradient Boosting) para predecir goles\_local y goles\_visitante de forma independiente, usando las mismas 19 features del modelo de partido. Los valores predichos se redondean al entero más cercano y se recortan a 0 como mínimo. Para garantizar coherencia en la quiniela, si el ganador predicho por el modelo de goles contradice al ganador predicho por el modelo de clasificación, se aplica un swap de goles.

### E. Simulación Monte Carlo

La simulación Monte Carlo ejecuta 10,000 iteraciones del torneo completo. En cada iteración: (1) se simula la fase de grupos con liga completa por grupo (todos contra todos), asignando puntos; (2) los dos primeros de cada grupo avanzan a octavos; (3) las fases eliminatorias se resuelven partido por partido sin empate permitido. Las probabilidades de cada partido se obtienen de un cálculo previo del modelo, que ya evaluó los 1,128 posibles enfrentamientos entre equipos. Los conteos de campeón, finalista y semifinalista a lo largo de las 10,000 simulaciones se convierten en probabilidades.

## VI. RESULTADOS

### A. Modelo de Resultado de Partido

Los seis modelos evaluados obtuvieron los siguientes resultados sobre el conjunto test temporal (partidos desde 2022):

TABLA 2. COMPARATIVA DE MODELOS

| Modelo              | Accuracy Test | CV Mean | CV std  |
|---------------------|---------------|---------|---------|
| Regresión logística | 0.6092        | 0.5567  | ±0.0197 |
| RF base             | 0.6341        | 0.6152  | ±0.0120 |
| RF optimizado       | 0.6370        | 0.6157  | ±0.0116 |
| GB base             | 0.6445        | 0.6230  | ±0.0121 |
| GB optimizado       | 0.6428        | 0.6256  | ±0.0109 |
| XGBoost optimizado  | 0.6405        | 0.6257  | ±0.0110 |

El mejor modelo fue Gradient Boosting base con 64.45% de accuracy en test. El classification report muestra el reto del empate: precision 0.46, recall 0.06, F1 0.10, mientras que la victoria local tiene F1 0.77. Esto refleja la alta varianza del empate como resultado y la ventaja de localía en datos históricos generales.




Fig. 6: Modelos de resultado de partido

### B. Importancia de variables – Modelo de Partido

El análisis de importancia de variables del Gradient Boosting revela una dominancia clara de la diferencia de ELO:

TABLA 3. IMPORTANCIA DE VARIABLES

| Feature                   | Accuracy Test |
|---------------------------|---------------|
| Elo_diff                  | 60%           |
| Is_natural (campo neutro) | 19%           |
| Elo_seq (ELO al cuadrado) | 5.7%          |

|                      |      |
|----------------------|------|
| Overall_diff         | 4.2% |
| Defense_diff         | 1.9% |
| Attack_vs_defense    | 1.3% |
| Resto (13 variables) | 7.9% |

El ELO y su término cuadrático concentran juntos el 65.7% de la importancia, confirmando que la diferencia de rating es el predictor más poderoso de resultados de partido. La variable in\_neutral captura el efecto de localía (importancia 19%), que desaparece en partidos de copa del mundo al usarse campo neutral.

### C. Modelo de Ronda Alcanzada

TABLA 4. COMPARATIVA DE MODELOS

| Modelo                 | Accuracy Test | CV Mean | CV std  |
|------------------------|---------------|---------|---------|
| Logistic Regression    | 0.3667        | 0.3905  | ±0.1747 |
| Random Forest opt.     | 0.4333        | 0.4571  | ±0.0857 |
| Gradient Boosting opt. | 0.5000        | 0.4238  | ±0.0945 |
| XGBoost                | 0.4000        | NaN     | -       |

El mejor modelo fue Gradient Boosting optimizado con 50% de accuracy en test sobre 6 clases. un clasificador aleatorio tendría ~16.7%. El modelo logra 14 predicciones exactas de 30 (46.7%). La mayor dificultad radica en las clases más raras (Champion, Runner-Up, Semi Finals) que tienen soporte muy bajo en el conjunto de entrenamiento. La Regresión Logística mostró alta varianza (±0.175) reflejando la inestabilidad en muestras pequeñas.

### D. Predicción de Goles

TABLA 5. MÉTRICAS DE PREDICCIÓN DE GOLES

| Modelo        | MAE   | RMSE  | Exacto (=) | Cerca (±1 gol) |
|---------------|-------|-------|------------|----------------|
| RF home goals | 1.065 | 1.373 | 28.9%      | 75.7%          |
| RF away goals | 0.745 | 0.972 | 39.5%      | 91%            |
| GB home goals | 1.037 | 1.333 | 29.0%      | 77%            |
| GB away goals | 0.737 | 0.959 | 40.3%      | 91.4%          |

Los goles del visitante se predicen con mayor precisión (MAE ~0.74) que los del local (MAE ~1.05). Esto se debe a que los goles del visitante tienen menor varianza en el set histórico. Más del 91% de las predicciones de goles visitante caen dentro del ±1 gol del valor real, lo que es útil para quinielas. Los modelos GB y RF tienen rendimiento muy similar en esta tarea.




Fig. 7: Goles reales vs predichos

En la figura 7 se puede observar la diferencia que se tiene entre los goles reales realizados con los predichos, por cada uno de los modelos. Se puede ver que en todos 2 goles es el más concurrido para todos, lo que quiere decir que hay una tendencia en que los 2 goles por partido es el más popular.

#### E. Simulación Monte Carlo – Favoritos del Mundial 2026

Tras 10,000 simulaciones del torneo completo, los 12 principales favoritos al campeonato son:

TABLA 6. MÉTRICAS DE PREDICCIÓN DE GOLES

| Equipo       | P(Campeón) | P(Finalista) | P(Semi final) | ELO  |
|--------------|------------|--------------|---------------|------|
| España       | 9%         | 15%          | 23%           | 2089 |
| Argentina    | 7%         | 12%          | 20%           | 2060 |
| Brasil       | 6%         | 11%          | 18%           | 1966 |
| Portugal     | 6%         | 10%          | 18%           | 1976 |
| Francia      | 5%         | 10%          | 16%           | 2003 |
| Alemania     | 5%         | 9%           | 17%           | 1923 |
| Inglaterra   | 5%         | 9%           | 15%           | 1969 |
| Colombia     | 4%         | 8%           | 15%           | 1964 |
| Países Bajos | 4%         | 8%           | 14%           | 1944 |
| Bélgica      | 4%         | 7%           | 14%           | 1871 |
| Croacia      | 3%         | 7%           | 12%           | 1907 |
| Uruguay      | 3%         | 6%           | 12%           | 1890 |
| Japón        | 3%         | 6%           | 12%           | 1907 |

España lidera con 9.63% de probabilidad de campeonato, impulsada por el mayor ELO del torneo (2089) y la mayor win rate (80%). La separación entre el primer y el segundo lugar (~3.5 puntos porcentuales) es relativamente amplia, mientras que del segundo al décimo los equipos están más comprimidos entre 6.1% y 3.8%. Marruecos aparece como el equipo de mayor win rate reciente (95%) dentro de su muestra de partidos.

#### F. Coherencia entre Modelos

La integración de los tres modelos produce un sistema coherente: el modelo de partido determina las probabilidades de avanzar en el torneo (usadas en la simulación Monte Carlo), el modelo de goles genera el marcador predicho, y la quiniela final reconcilia ambos al corregir inconsistencias donde el modelo de goles predice una victoria diferente a la

del modelo de clasificación. La columna `mc_favorito` en el CSV de quiniela identifica cuál de los dos equipos tiene mayor probabilidad acumulada de campeonato según la simulación.

## VII. DISCUSIÓN DE RESULTADOS

El modelo alcanzó un accuracy del 64.45% en la predicción de resultados de partidos, lo cual está en línea con lo que reporta la literatura sobre predicción deportiva. Estudios similares suelen encontrar rangos entre 55% y 65% para modelos de machine learning aplicados al fútbol internacional. Un hallazgo importante es la dificultad para predecir empates, reflejada en un F1 de apenas 0.10. Esto es algo recurrente: los modelos tienden a inclinarse hacia victorias locales o visitantes y terminan subestimando la frecuencia real de los empates. En cuanto al modelo de ronda alcanzada, el accuracy de 50% sobre seis clases ordinales resulta razonable considerando el tamaño limitado del dataset maestro, que incluye 31 equipos por mundial y solo 22 torneos disponibles. La principal limitación es el escaso número de casos en las rondas superiores, con apenas 21 campeones y 21 finalistas en toda la historia del dataset. El modelo logra identificar bien la fase de grupos, que es la clase mayoritaria, pero muestra dificultades en las etapas avanzadas.

El ELO se confirmó como la variable más influyente, con un peso del 56.1%. Esto era esperable, ya que el sistema fue diseñado justamente para medir la fortaleza relativa de los equipos. El término cuadrático (`elo_sq`), que aporta un 6.2% adicional, refleja que la ventaja de una diferencia de 200 puntos no equivale al doble de la de 100 puntos: cuando la diferencia es muy grande, el resultado se vuelve casi seguro. Por otro lado, la variable `is_neutral`, con un 17.4% de importancia, evidencia el efecto de la localía que se ha documentado en múltiples estudios. En el contexto del Mundial, los partidos se juegan en campo neutral o en la sede del anfitrión, lo que explica su relevancia.

El proyecto enfrenta varias limitaciones que vale la pena señalar. En primer lugar, el dataset maestro de rondas es pequeño, con 491 observaciones provenientes de solo 22 mundiales, lo que afecta la estabilidad de los modelos de clasificación multiclase. En segundo lugar, la calidad de los datos de `player_aggregates` disminuye en torneos más antiguos, especialmente antes de FIFA 15. En tercer lugar, el sistema de actualización por ronda se basa en un promedio ponderado simple, que podría mejorarse con enfoques bayesianos. Finalmente, existen factores externos que no están capturados en los datos y que pueden tener un impacto significativo, como lesiones, suspensiones, condiciones climáticas, cohesión del plantel y el efecto psicológico propio de un torneo de esta magnitud.

La ventaja que muestra España en la simulación está influida en parte por la composición de su grupo (H: Uruguay, Arabia Saudita, Cabo Verde), que resulta menos competitivo en comparación con otros, como el grupo L (Croacia, Inglaterra, Ghana, Panamá). El modelo de simulación refleja

esta heterogeneidad al evaluar cada grupo de manera independiente. Esto implica que equipos con un ELO alto, pero ubicados en grupos más exigentes, pueden ver reducidas sus probabilidades de campeonato en relación con lo que sugeriría su calidad intrínseca.

## VIII. CONCLUSIONES

Este Proyecto demostró que es posible construir un sistema de predicción estadísticamente fundamentado para la Copa del Mundo FIFA 2026 integrando datos heterogéneos y múltiples tareas de aprendizaje. Las principales conclusiones son:

- **Predicción de partidos:** El rating ELO es el predictor más poderoso (56.1% de importancia), seguido del efecto de campo neutral. Gradient Boosting con `learning_rate=0.05`, `max_depth=3` y `n_estimators=100` logró la mejor generalización (64.45% test accuracy).
- **Predicción de ronda:** Gradient Boosting optimizado alcanzó 50% de accuracy sobre 6 clases ordinales, superando significativamente el baseline aleatorio (16.7%). La restricción de cupos garantiza predicciones coherentes con la estructura real del torneo de 48 equipos.
- **Predicción de goles:** Los modelos de regresión predicen los goles del visitante con  $MAE=0.737$ , y más del 91% de predicciones caen dentro de  $\pm 1$  gol del valor real.
- **Simulación Monte Carlo:** Con 10,000 iteraciones, España sale como favorita (9.63%), seguida por Argentina, Brasil y Portugal. La dispersión de probabilidades refleja la alta competitividad del torneo expandido a 48 equipos.
- **Integración de modelos:** El sistema coherente que combina predicción de partido, predicción de goles y simulación Monte Carlo produce quinielas más informadas que cualquier modelo aislado.
- **Actualización dinámica:** El sistema de actualización por ronda permite incorporar resultados reales con doble peso (por ser partidos de Copa del Mundo) y recalcular favoritos y quinielas para las rondas siguientes

## IX. RECOMENDACIONES

Con base en los hallazgos del proyecto, se proponen las siguientes mejoras y extensiones para trabajos futuros:

- **Modelado de goles con distribución de Poisson:** Un modelo que prediga directamente la tasa esperada de goles por equipo y simule el marcador usando distribución de Poisson o negativa binomial mejoraría la predicción de empates y resultados atípicos.
- **Ampliar el dataset de ronda:** Incorporar datos de 2026 (el torneo en curso) y de otros torneos internacionales equivalentes (Copa América, Copa Africana de Naciones) para aumentar el soporte de las clases de rondas avanzadas.
- **Modelos secuenciales tipo ordinal:** Dado que `stage_reached` es ordinal, modelos de regresión ordinal o redes neuronales con función de pérdida ordinal podrían mejorar la calibración de probabilidades.

- **Incorporar datos de jugadores actuales individuales:** El cruce de `player_valuations` con selecciones nacionales mediante bases de datos como SoFIFA o FBref permitiría capturar lesiones de jugadores clave y composición real de la convocatoria.

## X. BIBLIOGRAFÍA

- [1] Martj42. (2025). International football results from 1872 to 2025 [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>
- [2] Abecklas. (s.f.). FIFA World Cup dataset [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/abecklas/fifa-world-cup>
- [3] Stefanoleone992. (s.f.). FIFA players statistics (EA Sports) [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/stefanoleone992/fifa-21-complete-player-dataset>
- [4] Cereijo, D. (s.f.). Transfermarkt player valuations [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/davidcariboo/player-scores>
- [5] Maso9999. (s.f.). FIFA World Cup 2022 matches [Conjunto de datos]. Kaggle.
- [6] The World Bank. (s.f.). World Bank Open Data. <https://data.worldbank.org>
- [7] Fédération Internationale de Football Association (FIFA). (s.f.). FIFA World Cup 2026™ official match schedule. <https://www.fifa.com/en/tournaments/mens/worldcup/canadamexicousa2026>
- [8] Constantinou, A. C., & Fenton, N. E. (2013). Determining the level of ability of football teams by dynamic ratings based on the relative discrepancies in scores between adversaries. *Journal of Quantitative Analysis in Sports*, 9(1), 37–50. <https://doi.org/10.1515/jqas-2012-0036>
- [9] Hvattum, L. M., & Arntzen, H. (2010). Using ELO ratings for match result prediction in association football. *International Journal of Forecasting*, 26(3), 460–470. <https://doi.org/10.1016/j.ijforecast.2009.10.002>
- [10] Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
- [11] James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An introduction to statistical learning: With applications in Python*. Springer.
- [12] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
- [13] Murphy, K. P. (2012). *Machine learning: A probabilistic perspective*. MIT Press.